

stockcorr 量化策略完全指南（从零基础到实盘流程）

本指南从基础概念出发，逐一讲解工具中 26 个指标的原理、目的与用法，并用真实数据（2013–2018 S&P 500，477 只股票，113,526 对组合）跑出的结果演示如何把它们组合成可执行的交易流程。

文中所有真实数字来自仓库内置漏斗在历史数据上的输出，用于演示方法论，不构成任何投资建议。

0. 两个地基概念

① 收益率 (Return)：我们几乎从不直接比较股价（AAPL \$200 vs KO \$60 没法比），而是比较每日对数收益率 $r = \ln(P_t / P_{t-1})$ 。所有“相关性”默认指收益率之间的相关性。

② 价差 (Spread)：两只股票的价格组合 $\text{Spread} = A - \beta \times B$ ，其中 β 叫对冲比率。配对交易的全部秘密：找到让这个价差“有规律”的股票对。

一、线性相关类

1. Pearson 相关系数 (pearson)

概念：衡量两只股票收益率同涨同跌程度，范围 [-1, +1]。协方差除以两者标准差之积。

目的：最便宜的第一道筛子——500 只股票 12 万对组合一秒算完，昂贵指标只对高 Pearson 对子算（这就是 --prefilter 的作用）。

作用：组合分散（买低相关股票降低组合波动）+ 漏斗预过滤。

交易举例（分散化）：已持有 NVDA，备选加仓 AMD（相关 ~0.8）或 KO（~0.2）。各配 50% 时：NVDA+AMD 组合波动 ≈ 单只的 95%（几乎无分散效果，等于芯片仓位翻倍）；NVDA+KO 组合波动 ≈ 单只的 77%（同样预期收益，回撤更小）。

新手最大误区：相关性高 ≠ 适合配对。两只股票可以收益率高度相关但价格越走越远（一只年涨 30%、一只年涨 10%，每天同向但差距越拉越大）。判断配对要用协整，不是相关性。

2. Spearman 秩相关 (spearman)

概念：先把收益率换成排名再算 Pearson，只关心方向一致性、不关心幅度，免疫极端值。

用法：当 Pearson 与 Spearman 差距大（如 0.7 vs 0.3），说明相关性主要由几个极端日贡献——平时不同步，只是一起崩过几次。筛选规则：只接受 $|\text{Pearson} - \text{Spearman}| < 0.15$ 的对子。

3. Kendall's τ (kendall)

概念：随机取两天，统计“A 与 B 相对走势一致”的比例。与 Spearman 信息高度重叠但更慢。

建议：大宇宙 (>200 只) 直接用 Spearman（工具会发警告）；Kendall 留给小样本（如月线只有 60 个点）。

4. 协方差 (covariance, 含 Ledoit-Wolf 收缩)

概念：未标准化的相关性，是 Markowitz 组合优化的直接输入（默认年化 $\times 252$ ）。

为什么要收缩：500×500 矩阵有 12.5 万个参数，5 年数据只有 1,260 天——参数比数据多，样本矩阵噪声主导。优化器会“精确放大噪声”给出极端仓位。Ledoit-Wolf 把矩阵向简单结构拉回，用一点偏差换大幅降方差。喂优化器时务必 shrinkage=True。

二、协整类 —— 配对交易的心脏

先理解“协整”：醉汉与狗

醉汉牵狗散步：醉汉走得歪歪扭扭（随机游走），狗也乱跑，但狗被绳子拴着——可以暂时跑远，总会被拉回。醉汉=股票 A，狗=股票 B，绳长=价差。单独哪只都不可预测，但价差可预测（总会回归）。两只股票被同一根绳子拴着，就叫协整。

什么股票会拴在一起？共享同一基本面驱动的：两家区域银行（同样的利率环境）、两家铁塔 REIT（同样的 5G 资本开支）、可口可乐与百事（同一个市场）。

5. Engle-Granger 协整检验 (coint)

概念：两步法——先 OLS 回归 $A = \alpha + \beta \times B$ 求对冲比率，再检验残差（价差）是否 平稳（不漂移、围绕均值震荡）。p 值越小越可能真协整。

真实例子：2013–2018 数据第一名 LNC（林肯国民，寿险）/ MS（摩根士丹利）： $p = 0.0001$ ， $\beta = 1.48$ 。经济逻辑：都是利率敏感金融股，被“利率”这根绳子拴着。

两个内置防坑：1. 多重检验：测 11 万对，纯噪声也有 ~5,500 对 $p < 0.05$ 。看 p_value_fdr 列。真实数据：105 对原始显著 → FDR-5% 后 0 对——大部分“协整”是幻觉。2. 方向不对称：回归 A 对 B 与 B 对 A 结果不同，工具双向都测取强的一边（direction 列）。

6. Johansen 检验 (johansen)

概念：基于 VECM，方向无关，可检验 3+ 只股票。

进阶玩法——协整篮子：三家航空公司两两不协整，但 $AAL - 0.5 \times DAL - 0.7 \times UAL$ 可能平稳。Johansen 的特征向量给出权重。三腿价差破 $-2\sigma \rightarrow$ 买 AAL、按权重空另两只。

7. 半衰期 (half_life) —— 决定赚不赚得到钱

概念：价差偏离后回归一半平均需要几天。AR(1) 回归 $\Delta \text{spread} = \alpha + \beta \times \text{spread}(\text{昨天})$ ，半衰期 $= -\ln(2)/\beta$ 。

为什么重要：协整说“会回归”，半衰期说“多久回归”：- 持仓周期 $\approx 1 \sim 2$ 个半衰期 - 资金效率：HL=17 天一年滚 ~10 轮；HL=170 天一年 1 轮，年化差 10 倍 - 成本覆盖：HL=2 天的价差波动太小，往返费用吃掉利润

筛选甜蜜区： $5 < HL < 60$ 天（漏斗默认值）。

输出即开仓信息：half_life_days / kappa / spread_mean / spread_std / z_score —— z_score 是当前价差偏离的标准差倍数，直接就是交易信号（见第九章）。

8. Hurst 指数 (hurst) —— 价差的性格测试

概念：序列是均值回归还是趋势，范围 0~1：- $H < 0.5$ 均值回归（涨了倾向跌回来）→ 配对交易要的 - $H = 0.5$ 随机游走（不可预测）- $H > 0.5$ 趋势（涨了继续涨）→ 动量策略要的

作用：对协整的二次确认（从波动缩放规律这个完全不同的角度验证）。LNC/MS 价差 Hurst = 0.27，与协整结论互相印证。反向用法：动量策略筛 $H > 0.6$ 。

三、领先-滞后类

9. 互相关函数 (cross_corr)

概念：比较 A 的今天与 B 的 k 天前。corr(A 今天, B 昨天) 高 → B 领先 A 一天。

作用：发现信息传导链。经典模式：行业龙头先动 → 小盘同行 1~2 天跟上。

交易举例（跟随策略）：发现 corr(小盘 X 今天, 龙头昨天)=0.4、lag=1。龙头今天大涨 3% → 收盘前买 X → 明天补涨时卖。0.4 不是每次都对，靠重复次数赢。

ADR 陷阱（看 has_adr 列）：TSM“领先”台湾本地股一天纯属时区假象（美股收盘时亚洲未开盘），不是可交易信息。

10. Granger 因果 (granger)

概念：把 B 的历史加入预测 A 的方程，若显著提高精度 → “B Granger-causes A”。与互相关的区别：控制了 A 自己的历史，问“B 是否有增量信息”。有方向、双向分测。

交易举例：若“铜价 Granger-causes FCX，最佳滞后 2 天”成立 → 铜两日累涨 >2% → 做多 FCX。大规模扫描看 p_value_fdr。

11. DTW 动态时间规整 (dtw)

概念：允许时间轴拉伸的形态相似度——A 三天走完的形态 B 五天走完，DTW 仍认为像。距离越小越像。

作用：找“节奏不同但剧本相同”的股票（供应链上下游传导有快慢）。已内置 Sakoe-Chiba 窗口（±10 天），不允许“今天匹配三年前”。

四、因子类 —— 把"市场"从噪声里剥出来

12. Beta (`beta`)

概念：股票收益 $\approx \alpha + \beta \times \text{市场收益}$ 。 $\beta=1.5$ ：大盘涨 1% 它平均涨 1.5%。

交易举例（市场中性对冲）：看好 NVDA 的 α 但不想赌大盘。NVDA $\beta=1.8$ ：买 \$100k NVDA + 空 \$180k SPY $\rightarrow$ 大盘涨跌净影响 ≈ 0 ，只赚 NVDA 跑赢市场的部分。

13. 滚动 Beta (`rolling_beta`)

概念： β 不是常数（2020-03 很多股票 β 翻倍）。输出 `last`（当前值——对冲用这个，不是 5 年平均）和 `std`（稳定性——std 大要更频繁再平衡）。

14. 残差相关 (`residual_corr`) —— 机构级筛选的秘密

概念：所有股票都跟着大盘动，任何两只都"看起来相关"。先把每只对市场（和行业 ETF）回归取残差，再对残差算相关——市场解释不了的共同驱动。

实测验证：剔除市场+行业因子后，普通行业股的残差相关掉到 ≈ 0 ；藏有共同驱动的对子 保持 0.63——信号与噪声干净分开。

筛选升级：高 Pearson + 高残差相关 = 真同质对；高 Pearson + 低残差相关 = 只是 都跟着大盘混的，剔除。

```
stockcorr analyze --tickers sp500 --metrics residual_corr \
--benchmark SPY,XLK,XLF,XLE,XLV --start 2023-01-01 --end 2026-06-01
```

15. 下行 Beta (`downside_beta`)

概念：只用大盘下跌日算的 β 。`asymmetry = 下行 $\beta$ /上行 $\beta$` > 1.3 的股票 "平时温顺、崩盘凶残"。

交易举例（风控）：构建防御组合时按 `asymmetry` 再筛一遍，剔除高不对称股——否则"防御组合"会在熊市现出原形。

五、波动率/尾部类 —— 危机时谁和谁一起死

16. 尾部相关 (`tail_dep`)

概念： $\lambda = P(A \text{ 暴跌} \mid B \text{ 暴跌})$ ——B 处于最差 5% 日子时 A 也在最差 5% 的条件概率。

为什么不能用普通相关：平时相关 0.3 的资产，崩盘时集体飙到 0.9（"最需要分散时分散失效"）。全样本平均完全掩盖这个现象。

交易举例（压力测试）：组合里 10 只"低相关"股票，尾部相关一查 7 只两两 >0.5 $\rightarrow$ 平时分散、崩盘时是一个仓位 $\rightarrow$ 减仓或买指数 put 对冲共同尾部。

输出带 `n_tail_obs` 和置信区间：5 年数据只有 ~63 个尾部样本，别对单个数字过度自信。

17. 波动率相关 (`vol_corr`)

概念：不看方向，看波动率水平是否同步。期权交易者用它判断：买 A 的期权时 B 的隐含波动率会不会跟着贵。默认非重叠窗口（重叠会系统性高估）。

18. DCC-GARCH (`dcc`)

概念：把相关性本身建模成每天变化的序列（GARCH 滤波 + 动态相关方程）。输出 `value` (均值)/ `last` (当前)/ `max` / `min`。

交易举例：SPY/TLT 的 DCC 长期为负 (-0.3)，是 60/40 组合的基石。当 `last` 翻正 并持续（如 2022 加息周期） $\rightarrow$ 债券不再对冲股票 $\rightarrow$ 60/40 失效，转向商品/现金对冲。

六、非线性类

19. 互信息 (`mutual_info`)

概念：信息论指标——知道 B 后对 A 的不确定性减少多少，捕捉**任何形状**的依赖。已归一化到 [0,1)，可直接与 |Pearson| 对照（原始 nats 在 `mi_nats` 列）。

20. 距离相关 (`distance_corr`)

概念：等于 0 当且仅当完全独立（Pearson=0 不保证独立）。

实战用法 (`nonlinearity` 列)：`nonlinearity = dCor - |Pearson|`。差值大（如 dCor 0.5 / Pearson 0.1）= 存在纯非线性关系，画散点图人工看。

交易举例：个股 vs VIX——平时无线性关系，但 VIX>35 时几乎所有股票暴跌（阈值型关系）。Pearson 看不见，dCor 看得见。发现后构建条件规则：VIX 突破 30 → 自动减仓 50%。

七、时变类 —— 关系会变，策略要跟着变

21. 滚动相关 (`rolling_corr`)

概念：60 天滑窗持续重算相关性。输出 mean/std/min/max + `stable` 标志。

核心洞察：**稳定比高更重要**。均值 0.75/std 0.08（任何时候都靠谱）远胜 均值 0.85/std 0.30（开仓时不知道处于哪种状态）。漏斗最后一关就是它。

22. Regime 条件相关 (`regime_corr`)

概念：按市场状态分组（如 VIX>20 为高波动期）分别算相关。

```
stockcorr analyze --metrics regime_corr --regime '^VIX:20' ...
```

交易举例：配对 A/B 低波动期相关 0.8、高波动期掉到 0.4 → 加开关：**VIX>25 停止开新仓**。反之危机期相关性更强的对子（避险资产）可只在危机期交易。

23. 突变检测 (`breakpoints`)

概念：PELT 算法自动找滚动相关的**结构断裂点**，输出断裂次数 + 最近断裂日期。

交易举例：KMB/PG 配对做了三年。工具报告 `last_break_date=2025-11-03`，查当天 新闻：KMB 宣布跨界收购——商业模式变了，绳子断了。**立即平仓退役这个对子**，不要等价差“回归”——它可能再也不回归。价差发散是配对交易最大亏损来源，突变检测是预警器。

八、其他相似度

24. Gatev 距离 (`gatev_distance`)

概念：1998 年开创配对交易学术研究的原始方法：价格归一化到起点=1，算轨迹的欧氏距离平方和。越小越像。

原版交易规则（教科书级）：1. 形成期 12 个月：全市场算距离，取最小的 20 对（工具默认 252 天形成窗口）2. 交易期 6 个月：价差破 $\pm 2\sigma$ 开仓做收敛 3. 收敛平仓；到期未收敛强制平仓；滚动重复

与协整怎么选：Gatev 简单稳健无参数但粗糙；协整精确但工序多。**双筛**（两种方法都入选）置信度最高。

25. 层次聚类 (`cluster` ，支持残差模式)

概念：以 $1-|corr|$ 为距离把宇宙自动分群。提供 benchmark 时自动用**残差相关**聚类（否则所有股票被大盘黏成一团——实测中 24 只行业股全进了同一簇）。

两大用途：1. 缩小配对搜索：只在簇内找协整对，11 万对变几千对 2. 发现 **GICS 分类错误**（真实 alpha 来源）

真实发现（2013–2018 数据）：- AMZN（官方：零售）→ 聚到互联网簇——交易特性是科技股 - AXP（官方：金融）→ 聚到可选消费簇——驱动是消费支出不是利差 - ADP（官方：工业）→ 聚到 IT 簇——payroll 软件公司

交易价值：行业中性策略按 GICS 对冲；知道 AXP 实际是消费股，用 XLY 而非 XLF 对冲它，你的"中性"比别人更真。

九、完整实战：一笔配对交易的全生命周期

第一步：筛选（每月一次）

```
stockcorr screen --tickers sp500 --start 2021-06-01 --end 2026-06-01 --out pairs.csv
```

漏斗自动执行：11 万对 → Pearson 预过滤 → 协整 → 前后半样本验证 → 半衰期 5~60 天 → Hurst<0.5 → 滚动相关稳定。真实输出第一名：

LNC/MS：β=1.48，半衰期 17.3 天，Hurst 0.27，当前 z = -2.01

第二步：读懂信号

z = -2.01：当前价差 LNC - 1.48×MS 比历史均值低 2 个标准差——LNC 相对 MS 异常便宜。赌注：价差回归均值。

第三步：开仓（金额按对冲比率配）

单笔资金 \$50,000：买入 LNC ≈ \$29,700，卖空 MS ≈ \$20,300（由 β=1.48 与两者价格换算）。之后大盘涨跌 3% 两腿盈亏基本抵消——只暴露在价差上。

第四步：退出规则（开仓前写死）

情形	规则	依据
止盈	z 回到 ±0.5 内平仓	均值回归完成
止损	z 突破 ±3.5 无条件平仓	协整可能已断裂
时间止损	持仓超 2×半衰期 ≈ 35 天未回归，平仓	回归速度不对 = 模型失效
结构止损	breakpoints 报新断裂 / 任一公司重大公告	绳子断了

第五步：预期核算

价差 σ ≈ \$2.00（spread_std 列），z 从 -2 回到 0 赚 2σ；半衰期 17 天 → 预期持仓 3~5 周 → 一年可滚 6~8 次。扣 borrow 费、佣金、滑点后看净期望。

第六步：组合风控

- 同时持有 5~10 个不同行业的配对。终选名单里金融对太多（LNC/MS、JPM/SCHW、KEY/MTB 高度同源）只能选 1~2 个，否则全组合在赌利率
- 用 tail_dep 检查各配对价差之间的尾部相关
- 每月重跑 screen，淘汰 stable=False 或出现 breakpoint 的对子

第七步：回测验证（先于实盘）

```
# 在更早的窗口选对，在之后的窗口回测 — 避免前视偏差
stockcorr screen --input-csv panel_2013_2015.csv --out pairs.csv
stockcorr backtest --input-csv panel_2015_2018.csv --pairs-csv pairs.csv \
  --entry-z 2 --exit-z 0.5 --stop-z 3.5 --cost-bps 5 --plot equity.png
```

回测器是逐日 walk-forward 的：每天只用当天之前的滚动窗口估计 β/μ/σ，持仓期间参数冻结（现实中你交易的是固定股数比），完整实现第四步的四类退出规则，并双边扣成本。输出每笔交易明细 + 组合权益曲线 + 夏普/最大回撤/胜率。

十、最后的清醒剂

- 历史协整 ≠ 未来协整。AET 后来被 CVS 收购退市——任何配对都有"绳子被剪断"的一天，止损纪律比选对更重要。

2. **FDR 教给我们的事**：105 个"显著"对严格标准下 0 个过关。统计显著性是廉价的，**经济逻辑 + 样本外验证**才贵。永远问：这两家公司**为什么该拴在一起**？答不出来就不做。
3. **成本是隐形对手**：每轮 4 笔交易 + 做空融券费。半衰期短、轮次多的策略对成本 极度敏感（回测时把 `--cost-bps` 调高一倍看策略还活不活着）。
4. **选对与交易必须分窗**：用同一段数据既选对又回测 = 前视偏差，结果必然好看且必然 不可复现。